Knowledge Graph Builder

Báo cáo tiến độ và kết quả nghiên cứu thực nghiệm

Kỳ báo cáo: 20–27 October 2026 · Cập nhật kỹ thuật: 27 October 2026
Application scope: oil wells · Ngôn ngữ triển khai trước mắt: English · Case study: BSEE, End-of-Well reports và AK-3 · Môi trường: local/on-prem

1. Tóm tắt tiến độ

Dự án hướng tới platform chuyển tài liệu kỹ thuật và structured data thành Knowledge Graph (KG) có evidence traceability, vận hành với local LLM. Nhóm thống nhất core theo hướng domain-agnostic; application triển khai và đánh giá trước mắt tập trung vào oil wells, với tài liệu, extraction, QA và evaluation bằng English. Trong kỳ báo cáo, ingestion, graph từ structured data và prototype extraction–review–QA đã chạy được; đồng thời nhóm khảo sát các phương pháp KG construction và kiểm chứng theo từng thành phần những hướng cải thiện độ chính xác, reproducibility và đánh giá.

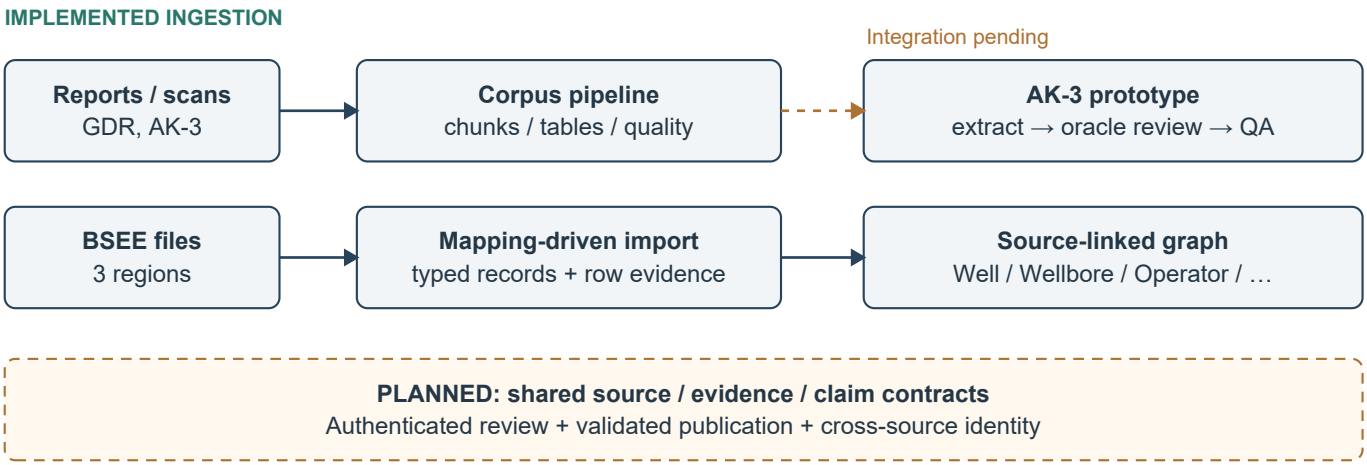
Hạng mục	Tiến độ nổi bật và trạng thái
PDF/OCR ingestion	3 technical reports, 155 trang, 372 chunk; tái chạy toàn bộ PDF ingestion trên CPU cho kết quả byte-identical. EasyOCR đã chạy trên scan Việt–Anh. Pipeline hiện tại bổ sung VietOCR/PP-OCRv6, per-page OCR và quality flags; đã xử lý 44 PDF phụ lục AK-3, 463 trang.
BSEE graph	Ingestion dữ liệu 3 vùng, có source tracking. Source-linked graph: 113.384 nodes / 398.263 edges. Expanded graph đã được nạp vào Neo4j, gồm 336.265 nodes kể cả metadata / 551.254 edges. Generic importer đã đối chiếu cùng record và graph counts với adapter.
Extraction và QA	Prototype AK-3 trên 15 chunk: precision 0.97, recall 0.68; QA end-to-end đúng 19/31 câu. Thử nghiệm canonicalization trên WebNLG-10 tăng strict F1 từ 0.736 lên 0.843.
Nghiên cứu và đánh giá	27 papers và code 13 repos được nghiên cứu; đã có ablation, đối chứng text RAG, quy trình AI-gold hai annotator và thử nghiệm extraction trên 49 đoạn EOR BSEE. Method suite có 354 tests pass; ingestion/application có 128 main tests và 4 prototype ontology tests pass.
Điểm nghẽn	Missed facts (recall), chất lượng OCR, expert validation cho gold và held-out evaluation cho prototype AK-3. Integration tiếp theo tập trung vào shared contracts, human review và publication chịu interruption.

Các số liệu ở trên đến từ những dataset, configuration và graph scope khác nhau. Đây là tiến độ của các hạng mục nghiên cứu và phát triển trong cùng một dự án; mỗi thí nghiệm giữ metric và artifact tương ứng. Các thành phần đang được nối qua source–claim–review–graph contract.

2. Mục tiêu, dữ liệu và kiến trúc hệ thống

2.1 Phạm vi và processing flow

Luồng thiết kế đã thống nhất: PDF ingestion → text/table extraction → chunking/source tracking → entity/relation extraction theo ontology → validation và human review → Knowledge Graph → evidence-based QA. Hai nguồn trọng tâm là BSEE Wells Information và English End-of-Well reports; AK-3 là geothermal development proxy đã dùng. Cross-source linking cần report về giếng thuộc BSEE. Well/wellbore là đối tượng chính; operator, lease, block và field hỗ trợ identity và context của giếng.



Hình 1. Document ingestion và structured-data import là hai source paths của dự án. Prototype đọc legacy chunks; dashed arrow thể hiện bước integration với corpus pipeline.

Traceability: document/source version, page/bounding box/offset, source file/row, quote, run/model/ontology version, processing bundle và review history.

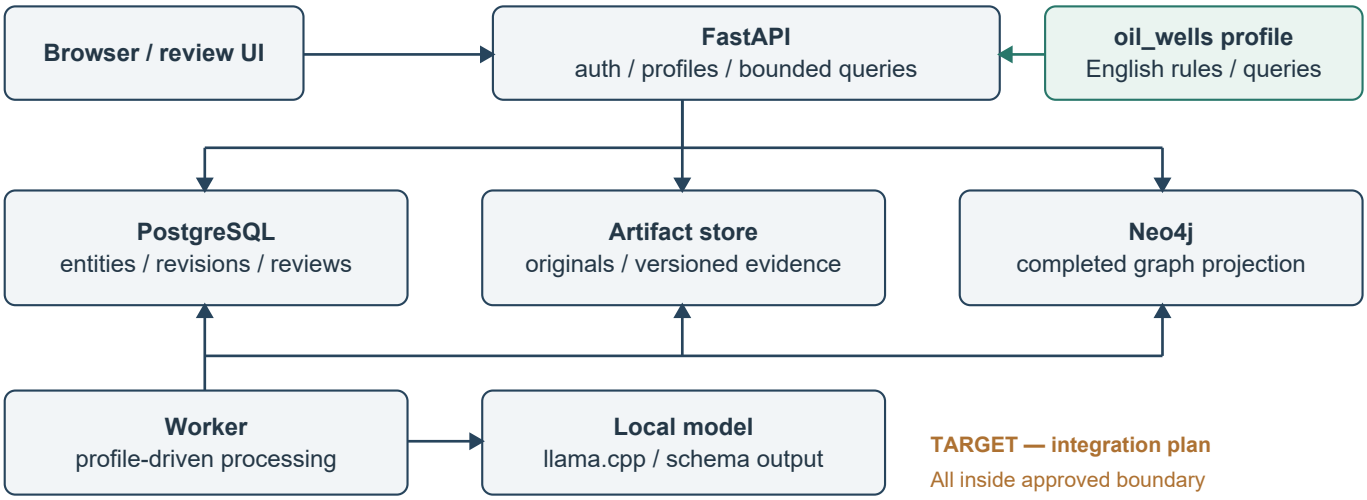
Stack dự kiến và đang thử nghiệm: Docling, VietOCR/PP-OCRv6, EasyOCR, FastAPI, PostgreSQL, Neo4j và llama.cpp; React/TypeScript dự kiến cho review UI. Các thí nghiệm phương pháp cũng sử dụng local model và các thư viện mã nguồn mở, theo source–claim–review–graph contract của kiến trúc chính. VietOCR/PP-OCRv6 là default OCR hiện tại; EasyOCR giữ làm đối chứng.

2.2 Các thành phần kỹ thuật đã triển khai

- **Kiến trúc/tài liệu:** sơ đồ data flow, catalog nguồn hiện có; ánh xạ section AK-3 sang actual/planned depth, casing, temperature, drilling time; cập nhật backlog, specification và development plan.
- **PDF extraction:** lưu document ID, physical page, bounding box và content offset; hỗ trợ text/table chunk, scan-page coverage, file integrity và cache khi nguồn/cấu hình thay đổi. Corpus pipeline bổ sung content-addressed catalog, per-page OCR, quality flags, parallel processing và resume.
- **BSEE ingestion:** tải dữ liệu Gulf, Pacific và Alaska; kiểm SHA256 từng file; lưu file/row nguồn; gộp well theo 10 chữ số đầu API number; nối wellbore–well–operator–lease–block–field và API number changes. Generic mapping tái tạo record và graph counts của adapter riêng.
- **Prototype kiến trúc AK-3:** Qwen2.5-3B qua llama.cpp trên CPU; LLM tạo fact và quote → validator → review queue → Neo4j theo generation → FastAPI trả lời có citation hoặc abstain khi thiếu fact. Generation checks hiện kiểm evidence của các claim đã project; exact accepted-set verification nằm trong backlog.
- **Các module được khảo sát và kiểm chứng theo bước:** open/schema-guided extraction, canonicalization, entity resolution, temporal/provenance, validation, graph storage và retrieval; các module có artifact, metric và replay riêng để phục vụ quyết định integration.

2.3 Kiến trúc và phạm vi integration tiếp theo

Giữ modular Python application, worker riêng và local model server trên approved host. Core quản lý source, evidence, entity, claim, review, publication và bounded query execution. PostgreSQL giữ authoritative state; artifact store giữ originals/evidence; Neo4j là rebuildable projection; SQLite của corpus giữ processing state cục bộ. Versioned oil_wells profile chứa ontology, BSEE identifier rules, units, MD/TVD và planned/actual context, extraction examples và trusted query catalogue. Ingestion đã domain-neutral; bước tiếp theo tách các well-specific assumptions trong prototype qua profile contracts.



Hình 2. Target architecture cho integration. Publication activate sau khi exact accepted set và evidence được kiểm đủ.

Workload ban đầu gồm 5–10 English well reports; triển khai 3 question intents trước và thống nhất 5–8 intents. Scope hiện tại gồm một oil-well profile; kiểm tra khả năng đổi cấu hình bằng synthetic profile fixture. Subsurface interpretation, expert-note workflows, domain khác và Vietnamese/Russian rollout chuyển sang giai đoạn sau. Kết quả Vietnamese OCR đã làm được giữ trong phần thực nghiệm. Private-data pilot cần authentication/roles, approved data boundary, independent backup/restore và operator.

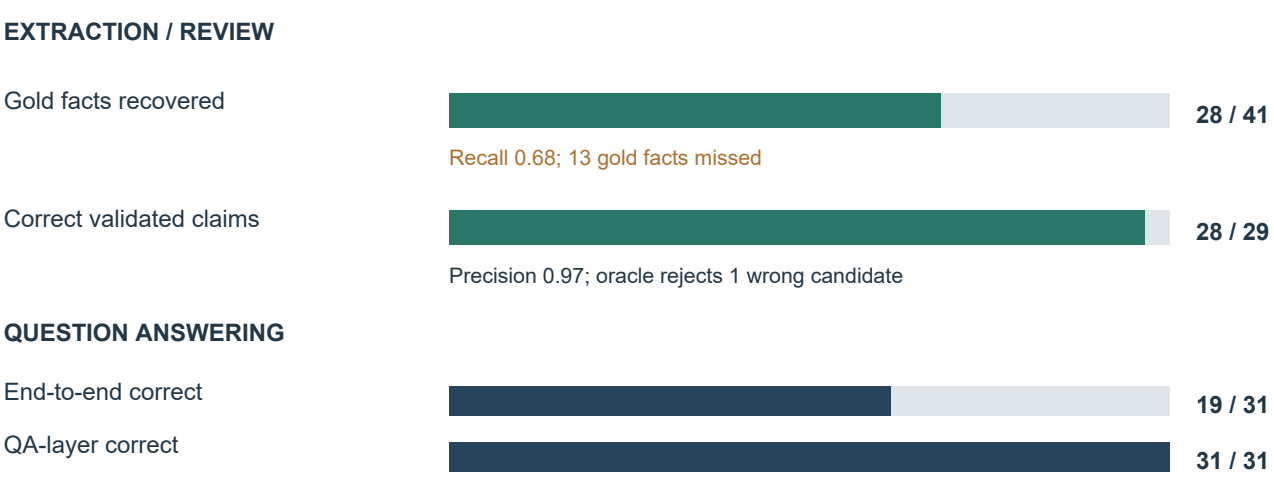
3. Kết quả ingestion, OCR và prototype AK-3

3.1 Dữ liệu thử nghiệm và kết quả ingestion (25–27/10)

Chỉ số	Kết quả
Bộ tài liệu	3 public technical reports: tổng 155 trang, 372 chunk (237 text, 135 table).
BSEE snapshot	57.453 boreholes / 39.518 wells; 587 API number change records.
BSEE linked graph	113.384 nodes / 398.263 edges; mỗi edge có row-level provenance.
Automated tests	128 main tests pass và 4 prototype ontology tests pass. Cached PDF regression pass; lượt review chạy main suite trong 17.191 giây, lượt kiểm sau cập nhật tài liệu trong 13.703 giây.
PDF rerun	Khoảng 13,5 phút trên CPU; output byte-identical với bộ đã publish.
Quantity recall	334/335 = 0.997 đối với drilling value kèm units.
Word-level quality	Recall median 0.954, min 0.442 (dense directional survey tables); precision 1.0 trong phạm vi phép chấm.
Locator và BSEE validation	Offset/bounding box hợp lệ 100% trong tập kiểm; BSEE có 0 malformed rows và 0 duplicate API numbers. Lượt cached regression ghi nhận Docling coordinate-clamping warnings.
Generic structured-data import	58.040 records gồm boreholes và API changes khớp adapter; cùng node/edge counts. Mapping bổ sung wrapper/helper fields và biểu diễn former API numbers qua edges.
Corpus pipeline	44 PDF phụ lục AK-3, 463 trang, 1.778 chunks, 336 tables; hai workers, resume và export đủ corpus.

3.2 Prototype AK-3: extraction, review và question answering

Prototype dùng 15 chunk / 41 gold facts / 31 câu hỏi. Sau extraction, precision là 0.97 và recall 0.68. QA-layer đúng 31/31 theo rubric cho phép honest no-answer khi graph thiếu fact; đánh giá end-to-end đúng 19/31. Lượt reviewed có 11/11 answered responses kèm citation/quote khớp chunk. Hai prompt injection giữ nguyên node/edge counts trong phép kiểm đã chạy.



Hình 3. Development slice của E4: recovered gold facts, correct validated claims và QA dùng denominator tương ứng. QA-layer rubric chấp nhận honest no-answer khi graph thiếu fact.

Vai trò của review: accept-all review để lọt một wrong value vào câu trả lời; oracle reviewer dựa trên gold set loại được trường hợp đó. Prompt đã chỉnh trên chính 15 chunk dùng để chấm, nên đây là in-sample evaluation. Human review và document-level held-out evaluation là bước tiếp theo. Tốc độ CPU khoảng 15 giây mỗi extraction passage và 4–6 giây mỗi câu hỏi trong môi trường thử nghiệm.

3.3 OCR trang scan Việt–Anh (24–27/10)

EasyOCR đã chạy end-to-end trên một trang có tiếng Việt, tiếng Anh, số và units: khoảng 52 giây/trang trên CPU. CER ≈10.5%, WER ≈19.5% so với reference của trang này. Output còn lỗi mất title, sai ký hiệu độ và punctuation.

Benchmark E5 bổ sung 11 born-digital pages render thành scans: 8 Vietnamese, 3 English. VietOCR được chạy chủ yếu ở scan200 và một clean page. So sánh cùng scan200 condition cho kết quả dưới đây.

Engine / language	CER ↓ (0–0.25)	WER	Word recall ↑ (0–1)	s/page
EasyOCR / VI	0.240	0.294	0.859	41
RapidOCR / VI	0.141	0.562	0.440	28
VietOCR / VI	0.052	0.082	0.945	48
RapidOCR / EN	0.021	0.044	0.998	13
VietOCR / EN	0.028	0.059	0.985	26

VI: 8 pages | EN: 3 pages | scan200 only | E5 synthetic scans

Hình 4. CER thấp hơn là tốt hơn; word recall cao hơn là tốt hơn. Runtime đo trên shared CPU; mỗi engine giữ cùng language/condition trong phép so sánh.

Default OCR hiện tại là VietOCR/PP-OCRv6. Với English oil-well workload, ưu tiên benchmark RapidOCR trên real scans, dense forms và degraded pages; pin cấu hình theo kết quả. VietOCR còn thiếu symbols như “°”.

3.4 Corpus run trên phụ lục AK-3

Đã xử lý 44 PDF, 463 trang bằng hai workers, export 1.778 chunks và 336 tables. Page modes gồm 359 text-layer, 71 full-page OCR và 33 hybrid; tổng cộng 104 pages có OCR. Năm pages flagged (4 missing, 1 review) đã kiểm bằng mắt. Dense Permit to Drill p.62 mất thông tin và bị nhận sai English thành Vietnamese; một contents page bị missing do text filter sau OCR.

Run 1 dừng chủ động ở 40/44: 35 done, 5 validation errors và 4 pending. Sau sửa rotated-page coordinates và table row range, run tiếp skip 35 documents đã hoàn tất, xử lý 9 documents còn lại trong khoảng 6 phút và export đủ 44. Hai runs có code change; single-run throughput và gold OCR transcription nằm trong bước đánh giá tiếp theo.

4. Nghiên cứu phương pháp xây dựng Knowledge Graph

4.1 Literature review và câu hỏi kỹ thuật

Đã đọc 27 papers, kiểm tra code của 13 repos mã nguồn mở, đồng thời khảo sát bổ sung các thư viện liên quan. Mục tiêu là kiểm tra: (i) mức phụ thuộc của extractor vào ontology; (ii) tác động của entity merging và relation canonicalization; (iii) evidence, temporal context và review status của fact; (iv) hiệu quả KG QA so với text retrieval; (v) khả năng chạy hoàn toàn local.

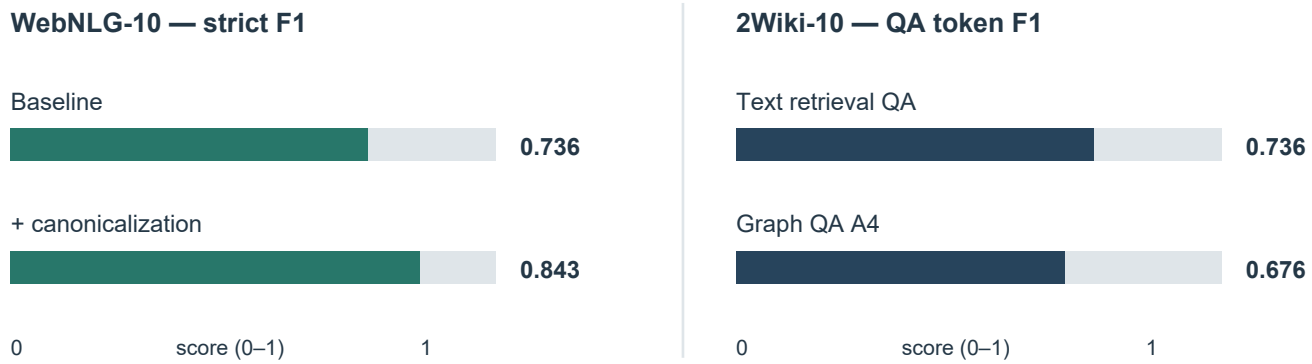
Vấn đề	Phương pháp đã tìm hiểu	Kết luận thực nghiệm / thiết kế
Extraction	KGGen (open extraction), EDC (schema-aware), GLiNER; đọc GenIE và các hướng khác	EDC phù hợp khi có target ontology; KGGen linh hoạt với free-form predicates. GLiNER nhanh trên CPU; accuracy là điểm cần cải thiện.
Ontology	EDC Define/Canonicalize, AutoSchemaKG	Canonicalize nhiều cách diễn đạt về một canonical relation; automatically generated ontology là gợi ý để người duyệt.
Entity resolution	SemHash/embedding, exact matching, domain rules	Similarity có thể merge nhầm số thứ tự/sidetrack. Match API number, lease và sidetrack trước; ambiguous cases chuyển review. Approximate search giữ cấu hình reproducible.
Grounding / temporal	Source offset và quote, version, temporal attributes; khảo sát Graphiti	Lưu evidence theo fact, phân biệt valid time và planned/actual; thiếu sentence context có thể khiến fact đúng bị loại.
Validation/review	Deterministic rules, LLM-as-judge, human review	Validator/judge từng loại nhầm fact đúng và làm giảm QA quality. Giữ candidates/risk flags để review; evidence cần sentence context, units, MD/TVD, planned/actual và negation.
Retrieval	Text RAG, graph retrieval; khảo sát GraphRAG, LightRAG, HippoRAG	Đo cùng model/câu hỏi và đối chiếu với text retrieval baseline.

4.2 Cấu hình thí nghiệm và phương pháp đánh giá

Các thí nghiệm phương pháp dùng local LLM Qwen3.6-35B-A3B (quantized MoE) trên CPU, kết hợp KGGen và EDC với các bước tự viết: provenance, temporal, normalization, validator, graph export và QA. Ablation bật dần thành phần: A0 baseline extractor; A1 thêm entity resolution; A2 thêm relation canonicalization; A3 thêm temporal; A4 thêm flag-based validation; A5 thêm LLM judge. Configuration, dữ liệu và model responses được lưu để offline replay và so sánh trên cùng input. SHA256, locator và model/ontology version được lưu theo run; replay 589/589 recorded calls cho cùng graph output. Method-evaluation suite có 354 tests pass, 0 skip; ingestion/application suite có 128 main và 4 prototype ontology tests pass.

Các bộ đánh giá: WebNLG-10 (triples có ontology), 2Wiki-10 (multi-hop QA), showcase nhỏ (alias, temporal, provenance), BSEE EOR (văn bản giếng khoan thực) và structured BSEE data. WebNLG-10/2Wiki-10 là mẫu nhỏ, có yếu tố in-sample; EOR dùng AI-gold và held-out test set. Mỗi bộ giữ metric và matching rubric riêng.

5. Kết quả ablation, QA và đánh giá domain BSEE



Hình 5. Method evaluation của dự án trên WebNLG-10 và 2Wiki-10; mỗi panel giữ metric và dataset tương ứng.

5.1 WebNLG-10: canonicalization là bước có lợi rõ nhất

Trên cùng 10 tài liệu WebNLG, strict F1 tăng từ 0.736 lên 0.843 khi bổ sung relation canonicalization theo EDC. Kết quả 0.843 tương đương EDC chạy riêng trên mẫu đó. Thí nghiệm chọn extractor khi đã có schema cũng cho kết quả cao hơn dùng KGGen cố định. Auto-routing cần thêm controlled comparisons. Các lượt WebNLG hiện là in-sample evaluation.

5.2 QA benchmark: text retrieval dẫn về token F1

Trên 2Wiki-10, cách tìm đoạn văn rồi dùng LLM trả lời đạt token F1 0.736, còn graph QA A4 đạt 0.676. Recall@5 của text retrieval đạt 0.975 trên tập văn bản nhỏ này. Kết quả cho thấy cần baseline text RAG mạnh và đánh giá theo nhóm câu hỏi multi-hop, cross-document và temporal. Evaluation hiện có 10 câu; bước tiếp theo mở rộng từng nhóm câu hỏi với cùng model và input corpus.

5.3 BSEE EOR: extraction trên dữ liệu thực

Đã xây bộ AI-gold 100 đoạn bằng hai AI annotators độc lập và adjudication, với evidence, dev/test split, freeze và hash. Trên 75 đoạn test, annotator agreement là 0.883 (value matching), 0.795 (full matching). Trong 50 đoạn được chọn chạy model, 49 đoạn chấm được; gold có 222 facts cho 49 đoạn. Lượt chạy có 489 model calls mới, 0 lỗi, mất 117.5 phút trên CPU.

Cấu hình	L1 Precision / Recall / F1	L2 F1	L3 F1
A0 (KGGen, free-form relations)	0.142 / 0.207 / 0.168	0.000	0.000
A4 (canonicalization, temporal, flags)	0.356 / 0.162 / 0.223	0.208	0.085
A4 sau strict filtering	0.365 / 0.153 / 0.215	0.201	0.088

Định nghĩa: L1 match value; L2 thêm ontology relation name; L3 thêm subject và attributes. A0 dùng free-form relation names, trong khi L2/L3 yêu cầu canonical ontology relations. Ở L1, A4 tăng precision nhưng giảm recall. ΔF1 L1 so A0 khoảng +0.054, bootstrap CI 95% [−0.0004, 0.125], khoảng ước lượng bao gồm 0. Ở L2/L3 tín hiệu rõ hơn và phụ thuộc ontology matching cùng AI-generated labels. Agreement hai annotators trên đúng 49 đoạn ở L1 là 0.879; recall A4 chỉ 0.162, vì vậy missed facts là điểm nghẽn chính.

5.4 Graph BSEE và kiểm tra Neo4j thực

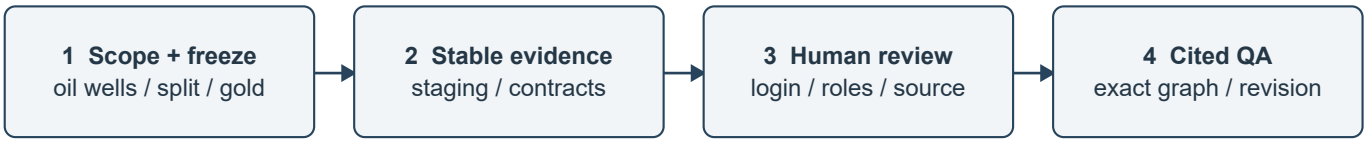
Bên cạnh source-linked graph ở mục 3, đã thử expanded BSEE graph cho các bảng và EOR records, sinh 336.264 data nodes và 551.254 edges. Bulk import CSV qua neo4j-admin database import vào database mới mất 633 giây (≈10.5 phút); kiểm lại Neo4j có 336.265 nodes (gồm 1 metadata node) và 551.254 edges, khớp manifest. Hai configurations giữ table/node scope và manifest riêng.

Trong thí nghiệm liên kết statements với bảng, có 61 links matched, 0 ambiguous và 94 unmatched; manual audit các links là bước tiếp theo. Bulk import thích hợp để dựng database mới; thêm claim từng lần và quản lý review cần parameterized writer, idempotency và data state.

6. Vấn đề, giới hạn và kế hoạch tiếp theo

Hạng mục	Vấn đề / giới hạn hiện tại	Việc tiếp theo
Recall / evaluation	AK-3 bỏ sót depth/temperature facts; prompt tune trên 15 chunks. WebNLG/2Wiki là mẫu nhỏ; EOR dùng AI-gold.	P0: freeze held-out split, expert adjudication; trace false negatives từ extraction đến validation; đối chứng text RAG.
OCR	Dense forms, directional survey tables và symbols còn lỗi. E5 dùng synthetic scans; E8 có visual checks qua hai runs.	Gold transcription trên English well-report scans và low-quality pages; benchmark RapidOCR/VietOCR theo loại trang.
Identity / ontology	Tên giếng trùng lease/sidetrack; ontology AK-3 và 21 EOR relations cần thống nhất.	P1: oil_wells profile/version contract; API–lease–sidetrack matching và MD/TVD/planned/actual rules qua profile/adapters.
Publication / validation	Two-rename interruption làm mất published path; validation sau installation; duplicate headers/IDs, invalid dates và cache/generation checks cần sửa.	P0: staging + immutable release pointer; exact accepted set, idempotent retry và source withdrawal.
Review / security	Human review, authentication, parser isolation và independent recovery đang chờ integration.	P1: source viewer, server-derived actor/roles, egress/log policy và restore test; ba cited question intents trước.
Compute / cost	E4 chạy CPU trên i5-1340P, 16 GB RAM. EOR 50 đoạn mất 117.5 phút CPU. GPU allocation, VRAM/RAM/disk và spending ceiling cần xác nhận.	Benchmark 3B/7–8B trên host thực; đo latency/memory/storage và reviewer time; ưu tiên school allocation.

Review workload minh họa: 5.000 pages × 3 candidates/page × 30 seconds/candidate = **125 reviewer-hours** trước corrections. Capacity cũ là 720 person-hours (576 delivery + 144 reserve); cần re-estimate phần còn lại theo một English oil-well profile, core interfaces và workload review.



NEXT MILESTONE — reviewed claim → cited answer

Exact evidence • interruption-safe replacement • source withdrawal

Hình 6. Evaluation → evidence → human review → cited QA; kiểm interruption và source withdrawal cùng luồng.

Cần thầy và anh xác nhận: VPI documents/quyền xử lý, paper OnePetro/EarthDoc, GPU và budget, expert reviewer, English oil-well question catalogue và operator nhận handover.

7. Đề xuất quy trình nghiệm thu bước tiếp theo

Để các kết quả ở những hạng mục hiện tại có thể được so sánh và tái kiểm tra trong cùng hệ thống, nhóm đề xuất quy trình đánh giá có input conditions và acceptance criteria định trước, kèm artifact của từng bước.

Thí nghiệm	Thiết kế tối thiểu	Artifact cần lưu
PDF/OCR	Phân tầng text PDF, scanned page, dense tables; kiểm word/quantity recall và source locator; báo số pages chấm	Original file và hash, text/chunk, locator, reference, error log
Extraction	Ontology đã duyệt; freeze gold/dev/test trước tuning, second annotator và expert review; chấm depth, temperature, casing, status cùng subject, units và context	Gold/annotation guide, raw output, agreement, P/R/F1, stage-level errors
Identity/claims	Giữ riêng khác API/lease/sidetrack; fact có quote và review status; rerun idempotent	Test cases, identity mapping, review decisions, graph counts
Question answering	Cùng gold Q&A/model: text RAG, graph QA, hybrid; kiểm EM/F1, wrong answers, abstention và citation/quote	EM/F1, Recall@k, citation audit, runtime
Reproducibility	Freeze dataset/ontology bằng SHA256; lưu model/config và replay; deterministic output comparison	Manifest, fixture record/replay, test results, delta giữa hai runs
Publication/security	Exact graph membership, completion marker, direct-route roles; crash/retry, withdrawal và independent restore	Expected IDs, fault tests, role checks, active-generation record, restore log và tombstones

Release gates dùng English oil-well workload: 200 held-out claims trên ít nhất 10 documents, 60 held-out questions, cùng identity/evidence/access/recovery checks. Scope và nguồn lực được chốt với domain reviewer và operator.

8. Tài liệu tham chiếu

Tài liệu dự án: docs/PROJECT_DESIGN.md, docs/DEVELOPMENT_PLAN.md, experiment register E1–E9, component guides và repository review. E1–E3 ghi ingestion/reproduction; E4 ghi AK-3 prototype; E5 ghi OCR benchmark; E6 ghi generic importer; E7/E8 ghi corpus pipeline; E9 ghi local verification và reproduced defects. Method evaluation gồm WebNLG-10, 2Wiki-10, BSEE EOR, ablation, graph import và record/replay.